

Debreceni Egyetem
Informatikai Kar
Adattudomány és Vizualizáció Tanszék

**Dinamikus objektumelkerülés megerősítéssel
a CARLA szimulátorban**

Témavezető:

Mészáros László
Tanársegéd

Készítette:

Angi Dávid
Adattudomány MSc

Debrecen, 2026

Tartalomjegyzék

1. Bevezetés	3
2. Kapcsolódó munkák	5
3. Elméleti háttér	5
3.1. Megerősítéses tanulás	5
3.2. Soft Actor-Critic	5
3.3. Autoenkóderek	5
4. A javasolt rendszer	5
4.1. Szimulációs környezet	5
4.2. Érzékelés és látens reprezentáció	5
4.3. Megfigyelési és akciótér	5
4.4. Jutalomfüggvény	5
4.5. Tanítási beállítások	5
5. Kísérletek és eredmények	5
5.1. Kísérleti beállítások	5
5.2. Eredmények	5
5.3. Ablációs vizsgálat	5
6. Összegzés és további munka	5
Irodalomjegyzék	6

1. Bevezetés

A 21. század egyik ha nem a legnagyobb hatású technológiai átalakulása a közlekedésben zajlik. Az elmúlt másfél évtizedben szemünk láttára kerültek önvezető járművek a kutatólaboratóriumokból a hétköznapi forgalom részévé. Kezdetben vezetéstámogató rendszerek (sávtartó automatika, adaptív tempomat, vészfékasszisztens) kirivó már technológiának számítottak azonban ma már a középkategóriás autókban is alapfelszereltség részét képezik, egyes városokban pedig sofőr nélküli robottaxik szállítják az utasokat. A fejlődés robbanásszerű gyorsulását a szenzorok relatíve olcsóbbá válása, valamint a járművekbe építhető, nagy teljesítményű számítási egységek megjelenése nélkülözhetetlen volt. Ezen felül az adatfeldolgozás és a mélytanulás fejlődése is kulcsszerepet ezen fejlődés történetében mivel, ezek a technológiák teszik lehetővé, a járművek számára környezetük érzékelését.

Az önvezető autók iránti érdeklődést elsősorban a biztonság motiválja. A közúti balesetekben világszerte évente több mint egymillió ember veszti életét [1], és a balesetek döntő többsége emberi hibára – figyelmetlenségre, fáradtságra, rossz helyzetmegítélésre – vezethető vissza.

Egy gép nem fárad el, semmi sem vonja el a figyelmét, és valamint a reakcióideje optimális esetben rövidebb lehet az emberinél. Ez az eset azonban csak akkor valósulhat meg, ha a vezetést végző algoritmus minden helyzetben megbízhatóan, hatékonyan és biztonságosan működik. Nem elég, ha a jármű az esetek túlnyomó részében – egyenes úton, jó időben, kiszámítható hanem nehézkes körülmények között is helyt kell állnia. Ezen oknál fogva avalódi kihívást a ritka, váratlan helyzetek jelentik, például a forgalom dinamikája, egy sávba kerülő akadály vagy egy előzés közben megváltozó forgalmi helyzet. Egyetlen rosszul kezelt helyzet is súlyos balesethez vezethet. (észlelés, predikció, tervezés, szabályozás) bontva oldják meg. Ezek a rendszerek jól értelmezhetők, de minden szabályt és határesetet előre meg kell fogalmazni bennük, ami a valós forgalom sokszínűsége mellett rendkívül nehéz. Alternatívát a megerősítéses tanulás (*reinforcement learning*, RL) kínál, amelyben az ágens nem előre megírt szabályokat követ, hanem a környezettel való interakció során, jutalmak és büntetések alapján maga tanulja meg, hogyan kell cselekednie. Ez a megközelítés különösen alkalmas az olyan döntési feladatokra, mint a sávtartás, az akadályok kikerülése vagy az előzés, ahol a helyes viselkedést nehéz szabályokkal leírni, de könnyű megmondani, hogy egy adott kimenetel jó vagy rossz.

A vezetési feladatot hagyományosan egymásra épülő, kézzel tervezett modulokra A megerősítéses tanulásnak azonban ára van: az ágens próbálkozások és hibák sorozatán keresztül tanul, és mielőtt elfogadható vezetési stratégiát alakítana ki, több százezer vagy akár több millió lépésen át, rengeteg ütközést elszenvedve kell gyakorolnia. Ezt valós járművel elvégezni gyakorlatilag kivitelezhetetlen. Egy szenzorokkal felszerelt tesztjármű, a zárt tesztpálya, a biztonsági sofőr és a karbantartás költsége rendkívül magas, egy ütközés pedig nemcsak anyagi kárt okoz, hanem emberi életet is veszélyeztethet. Ráadásul a legveszélyesebb, így a legfontosabb helyzeteket éppen a valóságban a legnehezebb szándékosan és megismételhetően előidézni. Becslések szerint

egy önvezető rendszer biztonságosságának pusztán valós tesztvezetéssel történő igazolásához több száz millió, esetenként milliárdnyi kilométer megtétele volna szükséges.

Ezért a tanítást és a tesztelést szimulált környezetben végeztük. A CARLA egy nyílt forráskódú, kifejezetten önvezetés-kutatásra fejlesztett szimulátor, amely valósághű városi és autópálya-környezetet, fizikai járműmodellt, forgalmat és a valós járművekben használtakhoz hasonló szenzorokat (kamera, LiDAR, radar, GNSS) biztosít. A szimulációban egy ütközésnek nincs következménye, a kísérletek tetszőlegesen megismételhetők, a nehéz helyzetek pedig célzottan előállíthatók. Így az ágens biztonságosan tanulhat a saját hibáiból, a kész modell viselkedése pedig reprodukálható módon, nagyszámú helyzetben értékelhető, mielőtt valós járműre kerülne.

Az önvezető rendszer döntései csak annyira lehetnek jók, amennyire pontos a környezetéről alkotott képe, ez a kép pedig kizárólag a szenzorokból származik. A kamera gazdag vizuális információt ad – felismerhetők rajta az útburkolati jelek, a sávok és a többi jármű –, ugyanakkor érzékeny a megvilágításra, és a távolságot csak közvetetten hordozza. A LiDAR ezzel szemben lézerimpulzusok segítségével pontos, a fényviszonyoktól független térbeli mérést ad a környező objektumok távolságáról. A két szenzor így kiegészíti egymást, együttes használatuk robusztusabb érzékelést tesz lehetővé. A szenzorok azonban másodpercenként óriási mennyiségű adatot állítanak elő, amelyet a járműnek valós időben kell feldolgoznia: 50 km/h sebességnél az autó másodpercenként közel 14 métert tesz meg, így már egy tized másodperces késés is csaknem másfél méternyi, „vakon” megtett utat jelent. A gyors és hatékony feldolgozás a tanulás szempontjából is kulcsfontosságú, hiszen a nagy dimenziós nyers képekből és pontfelhőkből közvetlenül tanuló ágens lassan és instabilan konvergál. Célszerű ezért az adatokat előbb egy kompakt, a lényeges információt megőrző reprezentációvá tömöríteni, és a döntéshozó ágens már ezen tanítani.

Dolgozatunkban ezt a megközelítést követjük. A CARLA szimulátor Town04 pályáján egy Soft Actor-Critic (SAC) algoritmussal tanított ágens fejlesztettünk, amely a kamera és a LiDAR adatait egy-egy autoenkóder segítségével alacsony dimenziós látens vektorokká tömörítve kapja meg, kiegészítve a tervezett útvonalra vonatkozó információval. Az ágens feladata a sáv biztonságos tartása, valamint a lassabban haladó járművek – mint dinamikus akadályok – szabályos, balról történő előzéssel való kikerülése. Megvizsgáljuk azt is, hogy a jutalomfüggvény kialakítása és a megfigyelési tér összetétele hogyan befolyásolja a megtanult vezetési stratégia minőségét.

2. Kapcsolódó munkák

Munkánk kiindulópontja a CARLA-SB3 tanítási környezet [mate2023carlasb3], amely egy variációs autoenkóder látens terével tanít SAC ágens. Hasonló, látens térben tanuló megközelítést mutat be chen2022interpretable.

3. Elméleti háttér

3.1. Megerősítéssel tanulás

3.2. Soft Actor-Critic

Az ágenszt a Soft Actor-Critic algoritmussal [haarnoja2018sac] tanítjuk, a Stable-Baselines3 könyvtár [raffin2021sb3] implementációját használva.

3.3. Autoenkóderek

A nagy dimenziós szenzoradatokat autoenkóderrel [hinton2006reducing] tömörítjük kis dimenziós látens vektorrá.

4. A javasolt rendszer

4.1. Szimulációs környezet

4.2. Érzékelés és látens reprezentáció

4.3. Megfigyelési és akcióter

4.4. Jutalomfüggvény

4.5. Tanítási beállítások

5. Kísérletek és eredmények

5.1. Kísérleti beállítások

5.2. Eredmények

5.3. Ablációs vizsgálat

6. Összegzés és további munka

Irodalomjegyzék

- [1] World Health Organization. *Global Status Report on Road Safety 2023*. Geneva: World Health Organization, 2023. ISBN: 978-92-4-008651-7. URL: <https://www.who.int/publications/i/item/9789240086517> (elérés dátuma 2026. 09. 29.).